awesome_loop_transformer • 汇总报告

循环 Transformer 与循环深度

GPT-6 Astra 背后的 Loop 技术全景：五篇核心论文 · 六十篇相关文献 · 十条趋势洞察（2018–2026）

基于微信文章《刚刚， GPT-6 Astra 背后的 Loop 技术全被挖出来了》串起的 5 篇论文，逐篇核对原文； arXiv 全量检索补齐 2018–2026 年约 60 篇相关工作 · 2026-09-06

github.com/asimfish/awesome_loop_transformer

一页结论

三句话说清这个方向在 2026 年的位置

首胜

算力匹配下第一次赢。
Loopie-20B-A2B 在与 Qwen3-30B-A3B 复现版相同的每步墙钟时间下训练 800B token，约 600B 后反超；SMELT 在 FLOPs / 参数 / KV 三重匹配下省 6.8–18% 训练 FLOPs。

胜利发生在「两步 · 逐层 · MoE」这个窄配置里。

2 vs 32

「循环几次」分裂成两个 regime。 预训练算力受限 → 2（Loopie、LoopCoder-v2、SMELT、Nanbeige）；推理算力可变 → 越多越好但要自适应（Huginn 到 32–64）。

「三次以上回退」是 PLT 并行设计的位置税，不是循环的普适上限。

超加

隐式循环 + 显式 CoT 互补。
LoopCoder-v2 在 R=2 上叠加 thinking 模式，LiveCodeBench +26.9，远超两者单独之和；LOTUS 首次在 3B 规模用潜在 CoT 追平显式 CoT。

标准 GRPO 与循环模型错配（RLTT、LoopRPT）。

给工程团队的一句话：中段循环、两次、layer-loop、MoE 骨干；部署前实测延迟和 KV cache—— 训练算力匹配的胜利不等于推理成本匹配的胜利。

数字来源：Loop the Loopies (2607.16051) · SMELT (2609.01343) · LoopCoder-v2 (2606.18023) · LOTUS (2606.31779)

概念

什么是循环 Transformer：同一组参数在深度上重复使用，深度与参数量解耦

四种循环粒度

- **model-loop**（UT 2018 · Huginn 核心 · Ouro）：L1→L2→L3→L1→L2→L3，整栈输出喂回
- **block-loop**（Huginn 三段式 · Hyperloop · Training-Free · SMELT）：首尾层不循环，中段重复；每步重新注入输入 e
- **layer-loop**（Loopie · Training-Free layer-mode · MixerLoop）：L1→L1→L2→L2→L3→L3，每层先局部迭代再下传
- **潜变量条件化**（Coconut · PLT 的 CLP · Latent Recurrent Transformer）：上一轮或上一 token 的隐状态作为条件注入；PLT 的 CLP 正是「两次饱和」的来源

三条正交设计轴

- **循环次数**：固定（Loopie、LoopCoder-v2）/ 训练随机 · 推理任选（Huginn）/ 逐 token 自适应停机（ACT、MoR、Think-at-Hard、RecurTrace）
- **训练方式**：从头预训练（Huginn、Ouro、Loopie）/ 改造已有模型（Relaxed Recursive、Retrofitted Recurrence）/ 免训练（Training-Free、Program-of-Layers）
- **目标把循环当什么**：截断展开的 LM（Huginn）/ 不动点（DEQ、STARS、Attractor）/ ODE 细化（Training-Free）/ 有监督潜在 CoT（LOTUS）/ 循环步 RL（RLTT、LoopRPT）

粒度分类沿用微信原文与 Loopie / Training-Free 的术语

时间线

八年：从 bAbI 过拟合的补丁，到前沿架构的候选组件

时间	事件
2016	Neural GPU · Adaptive Computation Time： 循环 + 自适应停机的前身
2018-07	Universal Transformers： **跨时间步共享参数、坐标嵌入、 ACT； bAbI 联合训练错误率 22.1 → 0.29**
2019–2022	ALBERT · Deep Equilibrium Models · deep thinking 系列（随机展开 + 输入注入） · 路径独立均衡模型
2023–2024	Looped Transformers as Programmable Computers · <10% 参数学会 ICL 算法 · MoEUT · Relaxed Recursive Transformers · Coconut
2025-02	Recurrent Depth / Huginn-3.5B： **800B token 训成，定名 recurrent depth； Saunshi 证明 k 层循环 L 次 ≈ kL 层**
2025-06–11	HRM · Mixture-of-Recursions · TRM · Ouro （2.6B， 7.7T token） · Parallel Loop Transformer · 扩散式并行采样器 · Think-at-Hard
2026-01–04	LoopFormer （ICLR） · RLTT （ICML） · LoopRPT · Hyperloop · 迭代深度扩展律 φ=0.46 · Loop-Think-Generalize （COLM）
2026-05	Training-Free Looped Transformers • **MELT • LT2 • LoopQ • STARS （ICML） • Attractor Models**
2026-06	LoopCoder-v2 **（7B PLT， 18T token，「只循环一次」） • 残差缩放 1/N 理论 • LOTUS • Program-of-Layers （ICML）**
2026-07	Loop the Loopies! **（Loopie-20B-A2B，算力匹配首胜） • Looped Latent Attention （KV 32×） • Nanbeige4.2-3B （28T token 产品模型）**
2026-09	SMELT 扩展律（省 6.8–18% 训练 FLOPs） · RecurTrace · GPT-6 Astra 发布， The Information 报道其使用 recurrent depth

五篇核心论文

一张表看五篇论文：各自回答一个问题，合起来是一条论证链

	Universal Transformers	Recurrent Depth (Huginn)	Training-Free Looped	LoopCoder-v2	Loop the Loopies
arXiv / 时间	1807.03819 · 2018-07	2502.05171 · 2025-02	2605.23872 · 2026-05	2606.18023 · 2026-06	2607.16051 · 2026-07
回答的问题	机制是什么	现代规模能训成吗	已有模型能白拿吗	部署时循环几次	算力匹配下能赢吗
粒度 / 次数	model-loop · ACT	block(2,4,2) · r̄=32	中间 4 层 · K=3 级 RK	model-loop(PLT) · R=2	layer-loop · R=2
训练	从头 ~65M	从头 3.5B · 800B tok	不训练 **0.6B–30B**	从头 7B · 18T tok	从头 20B-A2B · 3.5T
关键数字	bAbI 22.1→0.29	r 4→32： ARC-E 49.1→69.9	45 格 87% 非负	SWE-V 43.0→64.4→27.6	600B tok 后反超 30B-A3B
核心贡献	定义循环深度 + 停机	首次训成；隐空间轨道	层 = 欧拉步；子步	两步饱和诊断； CoT 超加	Loopie Recipe； SPT
最常被误读	—	「同样 0.8T」基线实为 0.18T	收益上限约 2–3 点	非单调是 PLT 特有	算力匹配 = 实测步时

论证链： UT 提出机制 → Huginn 证明可训 → Training-Free 证明可白拿并给出 ODE 解释 → LoopCoder-v2 给出部署时的循环次数与代价 → Loopie 在算力匹配下赢。

详细解读见 reports/zh/01–05

论文 01 • 2018

Universal Transformers：把 N 层换成同一层重复 T 次，再让每个位置自己决定想多久

机制

每个时间步 t 对所有位置并行：自注意力交换信息 → 位置无关的转移函数（FFN 或深度可分离卷积）。参数跨时间步共享；坐标嵌入 P^t = 位置正弦 + 时间步正弦，每步重新加入。 ACT 停机：每位置预测停机概率，累计过阈值即冻结状态。

留下的三个问题：参数—计算比（翻译只 +0.9 BLEU）；训练不稳定；推理成本无讨论。

2.3 → 3.8

bAbI 中需要 1 / 2 / 3 条支撑事实的问题， ACT 平均步数 2.3 / 3.1 / 3.8： 模型按需分配计算。干扰名词越多、优势越大——这个模式七年后在 Huginn 上原样重现。

任务	Transformer	UT	UT + 动态停机
bAbI 10K 联合训练（错误率 / 失败任务）	22.1 (12/20)	0.47 (0/20)	**0.29 (0/20)**
LAMBADA LM 测试困惑度	7321	319	**142**
WMT14 En-De BLEU （base）	28.0	**28.9**	–
Copy / Reverse / Addition 字符准确率（训 40 测 400）	.53 / .13 / .07	**.91 / .96 / .34**	–

论文 02 • 2025-02

Huginn-3.5B： Prelude → Core ×r → Coda，随机采样循环次数、只对最后 8 步反传

架构与训练

$e = P(x)$; $s_0 \sim N(0,\sigma^2 I)$; $s_i = R(e, s_{i-1})$; $p = C(s_r)$

- **输入注入**：像梯度下降每步都要用数据；只在第一步喂 e 的迭代不可能稳定。随机 s_0 + 注入 → 路径独立。
- **训练目标**： r ~ 对数正态泊松（均值 32，重尾）；**只对最后 k=8 步反传**，内存与 r 无关。
- **规模**： h=5280， (2,4,2)， 3.5B 参数； r=32 时有效深度 132 层。800B token， 4096 块 MI250X，恒定学习率 4e-5，三明治归一化。
- **两次失败**：隐状态坍缩（token 间相关度→ 1）；循环坍缩（r=1 与 r=32 困惑度相同）。

循环 r	ARC-E	ARC-C	HellaSwag	MMLU	GSM8K CoT
4	49.07	27.99	43.46	23.39	–
8	65.11	35.15	58.54	25.29	–
16	69.49	37.71	64.67	31.25	–
32	**69.91**	**38.23**	**65.21**	**31.38**	**34.80 / 42.08**

32B / 50B

「3.5B 打出 50B」是 FLOPs 等效：预训练每 token 原始 FLOPs 接近 32B 稠密模型，测试时可扩到 ~50B 的等效算力；基准分数接近 OLMo-7B、落后 OLMo-2。

公平对照只有 0.18T token （Table 4）： 同为 0.18T，循环模型 ARC-E 53.62 vs 46.42、 GSM8K CoT 10.24 vs 2.20； 后 620B token 学到的能力全部编码在循环里（r=1 成绩几乎不动）。

循环在哪里最有用、白拿的能力、以及隐空间里发生了什么

循环在哪里最有用

- 难任务（ARC-C）收益大，事实回忆（SciQ）收益小
- 上下文越多需要的循环越多： ARC-C 零样本 8–12 次饱和， 25–50 shot 需 32 次
- 开卷 OBQA +11.0 （38.2→49.2）：记的事实少，对上下文推理强
- **传播误差**：把 0.8T 的循环模型与 0.18T 的基线并列成「同样 0.8T」夸大了差距

零样本免费能力

- 逐 token 自适应停机（KL < 5e-4）：MT-Bench 5.63→5.56
- KV cache 共享（预算 4）：不掉分
- 连续 CoT：用上一 token 的 s_r 热启动，少走 1–2 步
- 自推测解码：少循环起草、多循环验证，无需 draft 模型

隐空间里发生了什么

- 多数 token 收敛到不动点
- 数值推理 token （GSM8K 的「3」）进入多维**轨道**
- 关键 token （「wrong」）表现为单向**滑块**，可能在计步
- 换 s_0 轨迹形状不变（路径独立）
- Lu et al. 2025 用 logit lens 只发现有限的可解释潜在 CoT 证据

Table 4 · Figure 9–12 · Section 6–7

论文 03 • 2026-05

Training-Free Looped Transformers：一层是 ODE 的一步欧拉，正确的循环是细分步长而不是走到 t=K

关键洞察

pre-norm 层 $L(x)=x+F(x) \Leftrightarrow \dot{x}=F(x)$ 上 h=1 的前向欧拉；post-loop 层是在 x(t=1) 的近似上训练的。

- **朴素循环** $x \leftarrow g(x)$ 做 K 次 = 积分到 t=K，后段层没见过 → 掉点（2 维小网络：K=8 时 MSE 335）
- **子步** $x \leftarrow (1-1/K)x+(1/K)g(x)$：以 O(1/K) 逼近同一个 x(t=1)；K=8 时 MSE 1.04
- **特殊 RK 表**：输出 $= \beta \cdot g(x_0) + (1-\beta) \cdot F^K(x_0)$，β 是锚点权重
- Anderson / heavy-ball / Aitken 都不如 RK 子步 → 预训练中段**不是压缩映射**，是 ODE 流

模型	基准	基线	循环	Δ pp
Qwen3-4B-Instruct	MMLU-Pro 5-shot	57.14	59.79	**+2.64**
	GPQA-Main 0-shot	33.71	35.71	**+2.01**
Llama-3.2-1B-Instruct	GPQA-Main	27.90	29.69	+1.79
Qwen1.5-MoE-A2.7B	ARC-Challenge 25-shot	48.29	50.60	**+2.30**
Moonlight-16B-A3B	OpenBookQA	31.60	32.80	+1.20
DeepSeek-V2-Lite-Chat	ARC-Challenge	57.94	58.79	+0.85
Qwen3-30B-A3B（事先锁定）	CSQA / MMLU-flex	78.71 / 66.67	79.85 / 67.46	+1.14 / +0.79

87%

45 个（模型，基准）格子非负；60% 正、27% 中性；配方：中间 4 层、3 级 RK、稠密 block / MoE layer，零调参

−27.7

循环整个模型（28 层）掉 27.73 点；n=4 +0.55，n≥6 悬崖；朴素循环 K=6 掉 17.71

0.5

最优窗口相对深度 0.43–0.71（>1.7B）；小模型前移到 0.25–0.56；MoE 必须 layer-mode（routing thrash）

论文 04 • 2026-06

LoopCoder-v2：在并行循环 Transformer 里，第二次循环几乎是全部——第三次开始交位置税

PLT 怎样把延迟和 KV 压平

- **共享 KV + 门控滑窗注意力**：第一轮 KV 冻结共享；后续轮 = 全局分支与局部滑窗（w=64）的逐头门控混合。KV 从 O(RLSd) 降到 O(LSd)
- **跨循环位置偏移 CLP**：B^(r) = Embed(x) + shift(h^(r−1))，上一轮状态右移一位，不同 token 的不同轮次可并行；延迟 ≈ 单次前向
- **代价**：token i 拿到的是邻居的状态 → 位置错配。7B，R∈{1,2,3,4} 各自从头训练 18T token，同一份 SFT，共 100 万 GPU 小时

7B 模型	HE+	LCB	SWE-V	Multi-SWE	TB-v2	BFCL	均值
基线 R=1	81.1	27.4	43.0	14.0	11.2	32.2	38.0
R=2	**84.1**	**35.4**	**64.4**	**31.0**	**21.0**	**40.1**	**46.5**
R=3	75.0	28.6	27.6	11.0	12.2	36.3	36.9
R=4	76.8	24.5	22.4	9.3	9.0	39.5	34.3

Table 2；SWE-V = SWE-bench Verified。R=2 的 64.4 超过 Kimi-Dev-72B（60.4）、Qwen3-235B-A22B（45.2），接近 Qwen3-Coder-480B（67.0）。

174.6

有效秩在第 2 轮达峰（172.5 → 158.2 递减）：后续循环在收窄表示子空间；更新方向震荡（cos θ < 0）

30–45×

CLP 偏移成本 Ω ≈ 常数，是第 3 轮起边际收益的 30–45 倍——

收益递减 + 固定成本 → R=2 达峰

+26.9

R=2 上叠加显式 CoT（Thinking）：LiveCodeBench 35.4→62.3，CRUX +6.6，超加性

适用边界：「两次最优」是 PLT 的性质（每次 R 单独从头训练，CLP 固定税）。顺序循环的 Huginn 到 r=32 单调上升。看有效秩曲线而不是穷举训练来选循环数。

论文 05 • 2026-07

Loop the Loopies!： layer-loop + 实测步时匹配 + 两次循环，循环 MoE 第一次在算力匹配下赢

Loopie Recipe （按实测优化器步时匹配）

1. 参考 Qwen3-like 30B-A3B （D=2048, L=48, R=1）→ 层数减半、循环两次：种子（2048, 24, 2）。块执行次数不变，**激活内存减半**（∝ s·b·D·L，随存储深度而非执行深度）
2. 省下的内存换**每卡 micro-batch 翻倍**（梯度累积减半，每步 token 不变）
3. 把效率增益再投资到宽度 / 深度，选实测步时最接近参考的候选 → Loopie-20B-A2B： D=2304， L=27， R=2，名义算力 1.42×，激活内存 0.63×

为什么 layer-loop 、为什么只两次

- 6B-A0.6B 上 layer-loop 约 1.2T token 后反超 model-loop；消融去掉 layer-loop 明显更差
- 流水线并行友好：一层的所有循环在同一 stage 内完成，无环回依赖
- N× 循环 vs N× 存储层（250B token）：边际收益在 R=2 最大，之后快速衰减
- **SPT 监督预训练**： SFT 的损失掩码 + PT 的优化规模（batch ≥1024 、序列 ≥ 128K 、 2T token 、 10 epoch）： 预训练与推理指标同时上升，无过拟合、无遗忘

~600B

800B token 算力匹配对照，约 600B 后反超 Qwen3-30B-A3B 复现版并保持领先； 4 级扩展梯全胜且差距不缩小

81.28

20B-A2B Thinking MMLU （3.5T token） vs Nemotron 3 Nano 80.52 、 Cascade 2 81.22 （各 25T）； AIME24 92.09

80.42

6B-A0.6B Thinking 的 AIME24 （Ouro 2.6B： 62.50）； AIME25 70.83； MATH-500 93.80

口径：名义 FLOPs 高 42%，但 MBS 2 vs 1 使每步墙钟时间持平——这是实测训练成本相等，不是 FLOPs 相等；推理成本未报告。

02

更广的图谱与十条洞察

arXiv 全量检索 · 约 60 篇直接相关工作 · 十个主题

文献图谱

十个主题： 2026 年上半年每个方向都有了专门的论文

理论

Giannou 2023 可编程计算机； Saunshi 2025 k 层 ×L 次 ≈ kL 层；Xu&Sato 2025 循环擅长 DAG 、 CoT 擅长自约化；

Zhang 2026 预算律

预训练

Huginn 3.5B/0.8T · Ouro 2.6B/7.7T · LoopCoder-v2 7B/18T · Loopie 20B-A2B/3.5T · Nanbeige4.2-3B/28T · SMELT 至 54B ； 循环数 2–4 ， MoE 成默认

效率

PLT 并行；扩散式采样器 5× ； MELT 常数 KV ； Looped Latent Attention 跨循环 KV 低秩 32× ； LT2 线性注意力； LoopQ W4A4

稳定性

残差缩放需 1/N 而非 1/√L ； DeepLoop 指数 1/4→1/2 ； Fully Looped 稳到 12 次； STARS 谱半径正则； settling / drifting 分类

停机

ACT · PonderNet · MoR （ NeurIPS 25 ） · Think-at-Hard （ 93% token 不循环） · LoopFormer 弹性深度 · RecurTrace 平均 2.0 次达 56.9%

改造

Relaxed Recursive （逐层 LoRA ） · Retrofitted Recurrence 课程 · Training-Free RK 子步 · Program-of-Layers 学跳过 / 重复程序

后训练

RLTT 沿潜在轨迹分配奖励 +10.9% · LoopRPT 强化预训练 · LOTUS 金标 CoT 监督潜在位置追平显式 CoT · LoopMTP · SPT

可解释

轨道 / 滑块（ Huginn ） · logit lens 证据有限（ Lu 2025 ） · 两尺度动力学 · Jacobian lens ： Ouro 每轮重建工作区、 Huginn 跨 16 轮携带

小模型

HRM 27M 解数独 / ARC · TRM 7M ARC-AGI-1 45% · Attractor Models 隐式微分、均衡内化 · Denoising Recursion 超过 TRM

应用

LoopViT 18M ARC 65.8% · RD-VLA 0%→90% 、 80× 加速 · 组合式工具调用随深度提升 · Nanbeige4.2-3B agentic 产品

完整清单与摘要： README · data/papers.csv · data/related_abstracts.json

洞察 1–3

算力匹配的门已过、但门很窄；循环次数分裂成两个 regime；粒度向中间收敛

1 · 窄门里的首胜

Loopie 与 SMELT 第一次在匹配训练成本下赢，但配置极窄： MoE 、 layer-loop / 中段、两次。 Schwethelm 的扩展律解释原因——一次循环只值 r^0.46 份独立参数（截断反传下 0.38 ），用循环换参数在 FLOPs 匹配下必输 ； Loopie 是用循环省下的**激活内存**换 micro-batch 再换宽度，理论 FLOPs 看不见这笔红利。

2 · 两个 regime

最优循环数： Loopie 2 · LoopCoder-v2 2 · SMELT 2 · Nanbeige 2 · Ouro 4 · Huginn 32 （可到 64 ） · RecurTrace 2.0 · Think-at-Hard 在 93% token 上 1 。分裂线是**算力约束在哪**：预训练受限 → 2 ； 推理可变 → 按需自适应（ Huginn ARC-C 随 few-shot 数从 8 次饱和到 32 次）。「三次以上回退」是 PLT 的位置税。

3 · 粒度变细、位置居中

整模型（ UT ）→ 三段式（ Huginn ）→ 逐层 / 中段（ Loopie 、 Training-Free 、 SMELT ） → 只循环 mixer （ MixerLoop 保留 41.5% 收益、省 45.9% FLOPs ）。三条独立证据指向同一位置：深度分数规则 0.43–0.71 （众数 0.5 ）、 SMELT 的「中间一半」、 Huginn 的首尾层特化。 MoE 必须 layer-loop ，免训练与从头训练两篇独立一致。

Loopie 2607.16051 · SMELT 2609.01343 · Schwethelm 2604.21106 · MixerLoop 2608.18230 · Training-Free 2605.23872

洞察 4–7

ODE 流还是不动点？稳定性成了定理；推理成本被拆成三件事；循环与 CoT 互补

4 · 两种哲学分化

Training-Free：预训练中段不是压缩映射，不动点加速器都不如 RK 子步 —— 对**已训练**模型顺着 ODE 流细分步长。另一支把循环**训成**不动点：STARS（谱半径正则）、Fixed-Point Reasoners、Attractor Models。Viakhirev：settling 算子加深不变差；Huginn 属 non-settling，LoopCoder-v2 的 $\cos\theta<0$ 震荡正是其表现。

5 · 稳定性从经验到定理

Huginn 的两次失败（2025）到 2026 年成了定理：残差缩放 $\varepsilon=1/N$ 而非 $1/\sqrt{L}$；DeepNorm 指数 1/4→1/2；最优学习率只依赖唯一层数、可跨循环数迁移。Fully Looped 稳到 12 次，LoopMTP 到 15 次。「循环模型难训」这道 2018 年以来的障碍基本被拆除。

6 · 推理成本拆成三个子问题

延迟：PLT 并行、扩散式并行采样器 5×。KV：共享（Huginn / MoR / MELT）或压缩（LLA：跨循环 KV 低秩，32× 近无损，H200 上批容量 32→768）。量化：LoopQ。三者独立可叠加。**口径警告**：Loopie 的算力匹配是训练步时；推理时每 token 54 次块计算 vs 48，未报延迟。

7 · 互补而非替代

LoopCoder-v2 R=2 叠加 thinking：LCB +26.9 远超各自之和；LOTUS 用金标 CoT 监督潜在位置，3B 追平显式 CoT，思考延迟降 2.5–6.9×。配套发现：**标准 RL 与循环模型错配**—— GRPO 只给最终潜在状态分配 credit；RLTT 沿轨迹分配后 Ouro-2.6B 数学 +10.9%；LoopRPT 在预训练就给潜在步分配强化信号。

STARS 2605.26733 · Think Shallow 2608.18222 · 残差缩放 2606.18524 · DeepLoop 2607.13491 · LLA 2607.15456 · RLTT 2602.10520

洞察 8–10

循环擅长「操作」知识而非「存储」；应用扩到 agent 与具身；生产化开始、工具链没跟上

8 · 能力剖面

Ouro 的对照把优势归因于知识操作而非容量；Huginn 闭卷弱、开卷 +11.0；Frey：循环帮数学、记忆库帮常识，合并才超 iso-FLOP 基线；Dual-Path 学到的门控让标点 / 符号 / 算术 token 走「深」、功能词走「宽」。**最佳搭档**：检索、长上下文、MoE 专家库——把存储外置。

9 · 从谜题到 agent

2025 年证据集中在数独 / 迷宫 / ARC / GSM8K；2026 年扩到三类：软件工程 agent（LoopCoder-v2 SWE-V +21.4）、工具调用（多步有依赖的调用随深度提升；Nanbeige4.2-3B 以 3B 超 Qwen3.5-9B）、机器人（RD-VLA 0%→>90%，比 token 推理 VLA 快 80×）。共同点：一次前向内维护中间状态与依赖。

10 · 工具链缺口

五个开源家族：Huginn、Ouro、LoopCoder-v2、Loopie、Nanbeige4.2-3B（28T token，已作为产品发布）。但复现报告显示 Nanbeige 在 HF transformers 上开箱 5 个 bug，修复后层复用仍使注意力内存翻倍。推理框架、量化、KV 管理都没有循环模型的标准接口；Loopie 的 megatron-loopie / vllm-loopie 分支是往这个方向的信号。

Ouro 2510.25741 · Frey 2603.08391 · Dual-Path 2605.30202 · Popescu 2608.18171 · RD-VLA 2602.07845 · Halloran 2608.13987

核对

五处被二次传播放大的说法，对照原文

常见说法	原文事实
Huginn 「同样 0.8T token 」下循环模型碾压基线	非循环基线只训了 0.18T；同为 0.18T 时循环模型 ARC-E 53.62 vs 46.42 、 GSM8K CoT 10.24 vs 2.20
「循环两次就够，三次以上回退」是循环 Transformer 的规律	是 PLT （跨循环位置偏移）特有的现象；每个 R 单独从头训练； Huginn 到 r=32 单调上升
Loopie 与 Qwen3-30B-A3B 「相同算力」	相同**实测优化器步时**； Loopie 名义 FLOPs 高 42% ，推理成本未报告；对照的是 800B token 自复现版
Training-Free 让开源模型「变强」	收益约 1–2.6 个百分点，集中在知识型多选题； 3B 以下蒸馏模型可能掉分；额外约 15–30% 推理延迟
Huginn 「 3.5B 打出 50B 的表现」	FLOPs 等效，非基准等效；基准上接近 OLMo-7B 、落后 OLMo-2-7B

> **方法：**每条都回到原论文的表号核对（ Huginn Table 4 、 LoopCoder-v2 Table 2 、 Loopie Table 1 与 §2.4 、 Training-Free Table 2–3 ）。

推断 · 明确标注

关于 GPT-6 Astra：能核实的与不能核实的

不能核实

Astra 用了哪种循环、循环几次、如何训练——OpenAI 发布页无架构细节，The Information 报道基于匿名信源，两份原始材料本报告作者均无法访问。

以下四条全部是基于公开文献的推断。

四条推断

1. 若 Astra 用 recurrent depth，公开文献中最接近「前沿规模 + 算力匹配」的配方是 Loopie / SMELT 路线：MoE、中段或逐层、循环次数很小。整模型循环 32 次的 Huginn 路线没有前沿预算下的算力匹配证据。

2. 「OpenAI 绕过了两次饱和」这一推测前提不成立——两次饱和是 PLT 特有；真正的瓶颈是推理成本，而 KV 32× 压缩、扩散式并行采样 5× 已把它压低一个量级。

3. 报道中的「安全担忧」对应文献里的真实问题：潜在推理无可读中间 token，探测结果依赖层与解码方式（Lu 2025、Jacobian Lens 2026），比监督 CoT 更难。

4. Loopie（7 月）、LLA（7 月）、SMELT（9/1）与 Astra（9 月初）密集出现：更合理的解读是多个团队在 2026 上半年同时把这个方向推到可用，而非某篇论文导致某个产品。

未解问题

七个还没有公开答案的问题

- **多循环的算力匹配。** 所有算力匹配的胜利都在 R=2； R≥4 能否赢没有公开证据
- **推理成本的完整账。** 训练步时、推理延迟、 KV 峰值内存需同时报告；目前没有一篇三者齐全
- **扩展律的函数形式。** SMELT 到 54B 、 Schwethelm 到 ~1B ；Chinchilla + r^φ 项在 100B+ 是否成立未知
- **自适应停机的预训练规模收益。** MoR / TaH / RecurTrace 都在 ≤ 8B ； 只有 Ouro 的熵正则深度分配在 7.7T token 验证过
- **潜在推理的可监督性。** LOTUS 需要金标 CoT ； 无 CoT 数据时如何让潜在轨迹可读、可审计，是安全层面的开放问题
- **layer-loop 的机制。** Loopie 三个理由中只有扩展性有实验；SMELT 的「第二次访问削弱注意力沉降」是唯一机制解释
- **循环 vs 序列长度扩展。** Hidden Decoding （WeLM 617B ）走序列维度并称更兼容流水线并行； Loopie 的 layer-loop 恰为流水线兼容而设计； 100B+ 上无正面对比

最值得做的两个空白： R≥4 的算力匹配扩展律；循环专用的 RL 目标（把 credit 分到潜在轨迹上）。

给从业者

三种预算下的可执行配方

零训练：已有模型

- 中间 4 层窗口， 3 级 RK 子步， β 取中间值
- 稠密 block-mode， MoE layer-mode （先固定路由）
- 先在知识型多选题上验证；预期 +1–2.6 pp，多 15–30% 延迟
- 任何「某段层跑两遍」的实验都用阻尼更新 x←(1−1/K)x+(1/K)g(x)

从头预训练：前沿预算

- MoE 骨干， layer-loop， R=2
- 层数减半 → 激活内存减半 → micro-batch 翻倍 → 用效率增益买宽度；按**实测步时**匹配算力
- SmallInit / 三明治归一化 / 残差 1/N 缩放；检查 r=1 与 r=max 的困惑度是否分开
- 后训练： SPT （SFT 掩码 + PT 规模）； RL 用轨迹级 credit （RLTT 类）

推理时可变算力

- 顺序循环（Huginn 类） + 训练时随机 r + 截断反传，推理任选 r
- 逐 token 自适应停机（KL 阈值 / 二阶步长差 / 学习式停机头）
- KV： 共享预算或 LLA 低秩编码；延迟： 扩散式并行采样
- 给它检索 / 长上下文——循环模型的强项是对上下文推理

部署前必做：实测延迟与 KV 峰值内存；不要把「训练算力匹配」当作「推理成本匹配」。

仓库导航

awesome_loop_transformer： 这份报告的全部材料

目录

- README.md — awesome 列表（14 个主题、 122 篇，五篇核心论文加星）
- papers/original/ — 五篇原文 PDF； papers/zh/ — 保版式中译 + QA 报告； papers/src/ — arXiv 全文
- reports/zh | en/ — 五篇逐篇深度解读； reports/pdf/ — 中、英文完整报告 PDF
- survey/zh | en/ — 趋势综述（Markdown + PDF）
- slides/html/ — HTML 演示（含 PDF 导出）； slides/beamer/ — Beamer PDF； slides/pptx/ — 本 PPTX
- data/ — papers.csv 、 related_abstracts.json ； src/generator.py 生成 README

方法与工具

- 翻译： SuperTranslate 保版式引擎（DeepSeek 后端） + 对象级 QA， 5 篇中 3 篇 0 issue， 2 篇为图内刻度 / 公式行的可解释误报
- 检索： arXiv API，关键词 looped / recurrent-depth / depth-recurrent transformer 、 latent reasoning ∧ loop， 60 篇摘要留档
- 写作：主张先行、必要限定只写一次、数字随处可核对（anti-defensive-writing / 说人话）
- 排版： pandoc + XeLaTeX （报告）、 Beamer 16:9 （学术幻灯）、 HTML 与本 PPTX （ppt-master technical-deepdive 风格， SVG → 原生 DrawingML）

github.com/asimfish/awesome_loop_transformer · 欢迎 PR 补充新论文（data/papers.csv → src/generator.py）